Mapeo de inundaciones con Sentinel-1 y una U-Net: ablaciones, generalización a Lima y fusión con Sentinel-2

Andhersson M. Salazar F.*, Alexander A. Chavez C.†, Alex R. Pomazón S.‡ y Christian A. Urviola G.§
Maestría de Especialización en Inteligencia Artificial
Universidad Nacional de Ingeniería, Lima, Perú
*andhersson.salazar.f@uni.pe, ORCID: 0009-0006-4517-5666
†alexander.chavez.c@uni.pe, ORCID: 0009-0000-0956-9082
‡alex.pomazon.s@uni.pe, ORCID: 0009-0004-8514-1546
§christian.urviola.g@uni.pe, ORCID: 0000-0003-4621-7128

***Resumen*—El radar de apertura sintética (SAR) de Sentinel-1 permite mapear inundaciones bajo nubes, pero su principio físico (el agua calma se ve oscura) tiene excepciones. Entrenamos una U-Net implementada desde cero con las polarizaciones VV y VH sobre Sen1Floods11 y la evaluamos con un protocolo de tres semillas. La pérdida combinada BCE + Dice y las conexiones de salto son las decisiones más influyentes, mientras que las etiquetas débiles de Otsu no mejoran al modelo. En test el modelo alcanza un IoU de agua de 0.669, frente a 0.554 de Otsu, y se mantiene en el evento no visto de Bolivia (0.663). En cambio, colapsa en la inundación de Lima de marzo de 2017 (IoU 0.003). Con imágenes antes y después del evento mostramos que allí el agua urbana y de huaico *se aclara* en el radar. Un análisis de fallos confirma con pruebas cuantitativas cuatro mecanismos (incidencia rasante, doble rebote, agua no especular y superficies secas lisas) y descarta un quinto. Finalmente, fusionar seis bandas de Sentinel-2 eleva el IoU de test a 0.848, aunque la ganancia proviene casi por completo del óptico y está favorecida por cómo se etiquetaron los datos.**

***Index Terms*—SAR, Sentinel-1, segmentación semántica, U-Net, inundaciones, Sen1Floods11, generalización geográfica**

I. Introducción

Las inundaciones están entre los desastres naturales que afectan a más personas, y su respuesta depende de saber *dónde* está el agua en las primeras horas. Las imágenes ópticas, las más fáciles de interpretar, suelen fallar justo entonces: el evento ocurre bajo nubes. El radar de apertura sintética (SAR) de Sentinel-1 no tiene esa limitación, pues ilumina la escena con microondas de día y de noche y atraviesa la nubosidad. Su principio físico para detectar agua es simple: una superficie de agua calma refleja el pulso de forma especular, lejos del sensor, y aparece oscura; el suelo rugoso y la vegetación retrodispersan energía y aparecen más claros.

Ese principio tiene excepciones que importan en el Perú. Durante el Niño Costero de marzo de 2017, los desbordes y huaicos de los ríos Rímac y Chillón inundaron zonas urbanas de Lima con agua turbulenta cargada de lodo, entre edificaciones y laderas empinadas: precisamente las condiciones en que el agua deja de verse oscura en el SAR. Un modelo entrenado con eventos de otros continentes, ¿sirve en ese escenario?

Este trabajo entrena una U-Net [1] implementada desde cero sobre el conjunto Sen1Floods11 [2] y la somete a un protocolo experimental con tres semillas por configuración. Las contribuciones son:

1. **Modelo base (E1):** U-Net propia en PyTorch con entrada VV y VH, sin librerías de segmentación, que supera al umbral de Otsu en test (IoU 0.669 frente a 0.554).
2. **Ablaciones (E2):** la pérdida combinada BCE + Dice es la mejor; quitar las conexiones de salto daña los ríos angostos; las etiquetas débiles no mejoran al modelo entrenado solo con etiquetas a mano.
3. **Evaluación en distribución (E3)** con matriz de confusión y análisis por evento.
4. **Generalización geográfica (E4):** el modelo se mantiene en Bolivia (brecha de 0.8 %) pero colapsa en Lima (IoU 0.003); diagnosticamos por qué con datos multitemporales.
5. **Análisis de fallos (E5):** cuatro tipos de fallo del SAR confirmados con una prueba cuantitativa cada uno, y una hipótesis descartada.
6. **Fusión con Sentinel-2 (E6):** añadir seis bandas ópticas sube el IoU de test en $+0.185$, con matices sobre cómo se construyeron las etiquetas.

II. Trabajo relacionado

Redes convolucionales frente a reglas. Los servicios operativos de mapeo con SAR se basan en umbrales sobre la retrodispersión, a menudo refinados con información auxiliar. Bereczky *et al.* [3] compararon varias CNN con una cadena operativa basada en reglas sobre Sentinel-1 y encontraron que las redes son competitivas con ella. Lee y Li [4] revisan la evolución del área, desde los umbrales hasta las CNN tipo codificador–decodificador y los modelos fundacionales.

Conjuntos de datos. Sen1Floods11 [2] ofrece 446 recortes etiquetados a mano de 11 eventos y miles de recortes con etiquetas automáticas obtenidas por umbral, lo que permite estudiar el valor de la supervisión débil. Le siguieron conjuntos más grandes y multimodales: MMFlood [5] añade relieve e

Tabla I
PARTICIONES USADAS. EL AGUA SE MIDE SOBRE PÍXELES VÁLIDOS.

Partición	Recortes	Uso
train	252	entrenamiento (9.4 % de agua)
valid	89	selección de modelo y de variantes
test	90	evaluación final en distribución (E3)
Bolivia	15	evento no visto (E4)
Lima	64	evento peruano no visto (E4)

hidrografía a Sentinel-1; S1S2-Water [6] empareja Sentinel-1 y Sentinel-2 a escala global; y Kuro Siwo [7] incluye imágenes SAR *antes* del evento, con el argumento de que la comparación temporal resuelve ambigüedades que una sola fecha no puede.

Inundación urbana. En ciudades el agua no siempre se oscurece: entre edificios aparece el doble rebote (fachada–agua–sensor), que la *aclara*. Zhao *et al.* [8] lo abordan con una U-Net consciente de lo urbano que combina intensidad multitemporal y coherencia interferométrica. Con intensidad de una sola fecha, como en este trabajo, esa información no está disponible.

Fusión SAR–óptico y modelos fundacionales. OmbriaNet [9] fusiona series temporales de Sentinel-1 y Sentinel-2 en una CNN supervisada para mapear inundaciones. El modelo fundacional Prithvi [10], preentrenado en imágenes ópticas, se ajusta en Sen1Floods11 con seis bandas de Sentinel-2 y alcanza un IoU de agua cercano a 0.8.

Brecha que aborda este trabajo. La mayoría de estos estudios reporta el desempeño en distribución. Aquí evaluamos además la transferencia a un evento peruano con etiquetas de un producto operativo (Copernicus EMS) y explicamos el fallo con mediciones físicas, no solo con la métrica. También cuantificamos, con el mismo protocolo, cuánto de la ganancia de la fusión se debe al óptico por sí solo.

III. DATOS

III-A. Sen1Floods11

Usamos los 446 recortes etiquetados a mano (*dorados*) de Sen1Floods11 [2]: imágenes Sentinel-1 GRD de 512×512 píxeles ($\approx$10 m) con las polarizaciones VV y VH en dB, y una máscara con tres valores: agua (1), no agua (0) y sin dato (-1). Respetamos las particiones oficiales (Tabla I): train, valid y test provienen de los mismos 10 eventos, mientras que Bolivia es un evento completo que nunca se ve en entrenamiento.

Para la ablación de supervisión débil usamos además los recortes *débiles* del conjunto, cuyas etiquetas se obtuvieron con el umbral de Otsu sobre el propio SAR. Excluimos los de Bolivia y los que coinciden con un recorte dorado, para evitar fuga de información. Comparada con la etiqueta a mano en los recortes dorados, esa etiqueta automática solo alcanza un IoU de 0.495, con mucha comisión en zonas áridas (Somalia, Pakistán): es una supervisión barata pero ruidosa.

III-B. Evento de Lima (marzo de 2017)

Construimos un conjunto de evaluación propio con la misma grilla que Sen1Floods11. La imagen es la escena Sentinel-1B del 17/03/2017 (10:38 UTC, órbita descendente relativa 171, VV+VH), obtenida ya calibrada y ortorrectificada desde Google Earth Engine. Las pasadas ascendentes sobre Lima solo traen VV, por lo que no sirven para un modelo de dos canales. La etiqueta es la capa de máxima extensión potencial de la inundación del producto EMSN038 de Copernicus EMS (13.58 km^2), delineada con imágenes ópticas WorldView-2 del 18 y 21 de marzo. Solo se evalúa dentro del área cubierta por esas imágenes (1 326 km^2). Los cauces de los ríos Rímac y Chillón que quedan fuera de la inundación se marcan como -1, porque son agua permanente que la etiqueta no considera inundación. Resultan 64 recortes con solo 1.05 % de agua. En 15 de ellos hay píxeles con VV = VH = 0 dB fuera de la franja del satélite; se marcan como -1 al leer.

III-C. Preprocesamiento

Cada banda se recorta a sus percentiles 1 y 99 y se estandariza con media y desviación calculadas *solo en train* (VV: -10.42 ± 4.08 dB; VH: -17.27 ± 4.79 dB). Los píxeles SAR no finitos ($\approx$2.5 M en train) pasan a 0 en la entrada y a -1 en la etiqueta, de modo que ni se aprenden ni se evalúan. En entrenamiento se toman recortes aleatorios de 256×256 con volteos y rotaciones de 90°. Estas transformaciones no interpolan, así que la máscara conserva sus tres valores. Valid, test y las regiones externas se evalúan con el recorte completo de 512×512, sin aumentos.

IV. METODOLOGÍA

IV-A. Arquitectura (E1)

Implementamos la U-Net [1] en PyTorch sin librerías de segmentación. El codificador tiene cuatro niveles; cada uno aplica un bloque *doble convolución* (conv 3×3 – BatchNorm – ReLU, dos veces) y un *max pooling* de 2×2. Los canales se duplican en cada nivel ($32 \to 64 \to 128 \to 256$, con 512 en el cuello de botella). El decodificador sube la resolución con convoluciones transpuestas y concatena el mapa del mismo nivel del codificador (conexión de salto) antes de otro bloque doble. Una convolución 1×1 produce un logit por píxel. A diferencia del original, usamos *padding* para que la salida tenga el tamaño de la entrada, y BatchNorm. El modelo tiene 7.76 M de parámetros y un campo receptivo efectivo, medido con gradientes, de 188 píxeles ($\approx$1.9 km). La entrada son los dos canales VV y VH; en el bono (E6) solo cambia el número de canales de entrada.

IV-B. Funciones de pérdida

Sea $p_i = \sigma(z_i)$ la probabilidad de agua del píxel i y Ω el conjunto de píxeles válidos ($y_i \neq -1$). Comparamos:

$$\mathcal{L}_{\mathrm{BCE}} = -\tfrac{1}{|\Omega|} \textstyle\sum_{i \in \Omega} \big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \big], \quad (1)$$

$$\mathcal{L}_{\mathrm{Dice}} = 1 - \frac{2 \sum_{\Omega} p_i y_i + \epsilon}{\sum_{\Omega} p_i + \sum_{\Omega} y_i + \epsilon}, \quad (2)$$

$$\mathcal{L}_{\mathrm{comb}} = 0.5\, \mathcal{L}_{\mathrm{BCE}} + 0.5\, \mathcal{L}_{\mathrm{Dice}}. \quad (3)$$

La BCE promedia por píxel y, con 9.4 % de agua, la dominan los píxeles de fondo. El Dice mide el solapamiento de la clase agua, no depende de los verdaderos negativos y está ligado al

Tabla II
ABLACIÓN (B) EN VALID: MEDIA ± DESVIACIÓN SOBRE 3 SEMILLAS.

Variante	Saltos	IoU	Precisión	Recall
Otsu (referencia)	—	0.507	0.634	0.716
BCE	sí	0.621 ± 0.002	0.844	0.702
Dice	sí	0.634 ± 0.009	0.800	0.753
BCE + Dice	sí	$\mathbf{0.644 \pm 0.002}$	0.822	0.749
BCE	no	0.584 ± 0.007	0.773	0.706

F1. Lo calculamos sobre todo el lote para que los recortes sin agua no lo vuelvan inestable. Verificamos que las tres pérdidas valen ≈ 0 con una predicción perfecta y que el gradiente en los píxeles -1 es exactamente cero.

IV-C. *Métricas*

Reportamos para la clase agua IoU, F1, precisión y *recall*, junto con la omisión (1−recall, agua no detectada) y la comisión (1−precisión, falsa alarma). Los conteos VP, FP, FN y VN se *suman* sobre todos los recortes de una partición antes de calcular las métricas. Así cada píxel pesa lo mismo y los recortes sin agua no producen divisiones $0/0$. La línea base es el umbral de Otsu del conjunto, evaluado con la misma máscara de píxeles válidos.

IV-D. *Entrenamiento y protocolo experimental*

Optimizamos con AdamW (tasa 10^{-3}, decaimiento de pesos 10^{-4}) y lotes de 8, con 3 épocas de calentamiento lineal seguidas de un decaimiento coseno, y precisión mixta. Todas las variantes tienen el mismo presupuesto: 60 épocas como máximo y parada temprana con paciencia 15 sobre el IoU de valid. Guardamos el modelo de la mejor época.

Cada configuración se entrena con **tres semillas** (42, 7 y 123), que cambian la inicialización, el orden de los lotes y los aumentos, y se reporta media ± desviación. Una diferencia se considera real solo si supera la variación entre semillas. Las variantes se comparan *únicamente en valid*; test se evalúa una sola vez con el modelo elegido y un umbral de 0.5 fijado de antemano. Las corridas se ejecutaron en GPU T4 (Colab y Kaggle), lanzando un proceso independiente por GPU cuando había dos disponibles.

V. EXPERIMENTOS Y RESULTADOS

V-A. *Ablación (b): función de pérdida y conexiones de salto*

Entrenamos cuatro variantes con solo los recortes dorados (Tabla II, Fig. 1). Tres cambian únicamente la pérdida; la cuarta usa BCE y elimina las conexiones de salto, de modo que el decodificador reconstruye la máscara solo desde el cuello de botella.

Pérdida. Con BCE la red es conservadora: alta precisión (0.844) pero recall de 0.702. Es lo esperado con 9.4 % de agua, porque declarar "no agua" en caso de duda casi no se penaliza. El Dice, que solo mira el solapamiento de la clase agua, invierte ese balance (recall $+0.051$, precisión -0.044) y sube el IoU, pero con una variación entre semillas cuatro veces mayor, consistente con sus gradientes más ruidosos. La

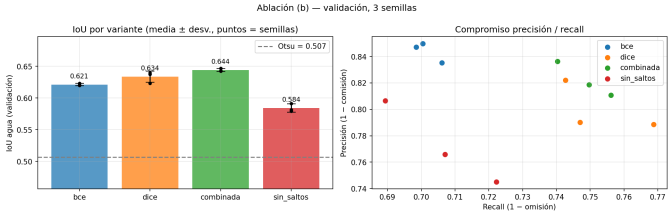


Figura 1. Ablación (b): IoU de valid por variante; cada punto es una semilla y la línea punteada es Otsu.

Tabla III
ABLACIÓN (A) EN VALID: MEDIA ± DESVIACIÓN SOBRE 3 SEMILLAS.

Estrategia	IoU	Precisión	Recall
Otsu (referencia)	0.507	0.634	0.716
Solo débiles	0.562 ± 0.009	0.731	0.709
Mezcla dorados + débiles	0.571 ± 0.004	0.751	0.706
Preentreno + ajuste	0.641 ± 0.005	0.823	0.744
Solo dorados	$\mathbf{0.644 \pm 0.002}$	0.822	0.749

combinación obtiene el mejor IoU (0.644) con la estabilidad de la BCE: conserva casi todo el recall del Dice (0.749) y recupera parte de la precisión (0.822). La mejora sobre BCE ($+0.023$) es unas diez veces su desviación, por lo que no se explica por el azar de la semilla. Es la pérdida que usamos en el resto del trabajo.

Conexiones de salto. Quitarlas baja el IoU de 0.621 a 0.584 con la misma pérdida (-0.037, unas cinco desviaciones). En el agregado la pérdida es sobre todo de precisión (0.844 a 0.773; la comisión sube de 0.156 a 0.227): sin el detalle fino, los bordes del agua se "derraman" sobre el fondo. La caída tampoco es uniforme: se concentra en los eventos con ríos angostos y bordes finos (Estados Unidos -0.10, España -0.08 de IoU). Tras cuatro reducciones, un río de pocos píxeles de ancho ya no existe en el cuello de botella; los saltos devuelven al decodificador ese detalle espacial de alta resolución, que es justo la motivación original de la U-Net [1].

V-B. *Ablación (a): etiquetas débiles*

Con la pérdida combinada comparamos cuatro formas de usar los recortes débiles (Tabla III). *Solo dorados* es el modelo de la sección anterior. *Solo débiles* entrena únicamente con etiquetas de Otsu. *Mezcla* añade 750 recortes débiles por época a los 252 dorados. *Preentreno + ajuste* entrena 30 épocas con débiles (1 000 por época) y luego ajusta solo con dorados, partiendo de esos pesos. Muestrear los débiles en cada época mantiene un costo de minutos por corrida; a lo largo del entrenamiento cada recorte débil se ve varias veces.

Tres observaciones. Primera: la red entrenada *solo* con etiquetas de Otsu supera a su propio maestro (0.562 frente a 0.507). Al aprender un mapeo suave con contexto espacial promedia parte del ruido de un umbral aplicado píxel a píxel. Segunda: mezclar débiles con dorados *empeora* el modelo (-0.073). Los débiles son tres veces más numerosos en cada época y dominan el gradiente, de modo que la red hereda los errores sistemáticos de Otsu, en especial la comisión en

Tabla IV
TEST (EVENTOS VISTOS, RECORTES NO VISTOS). U-NET: MEDIA ± DESVIACIÓN SOBRE 3 SEMILLAS, UMBRAL 0.5.

Métrica	Otsu	U-Net (BCE + Dice)
IoU	0.554	$\mathbf{0.669 \pm 0.003}$
F1	0.713	0.801
Precisión	0.682	0.815
Recall	0.748	0.789
Omisión	0.252	0.211
Comisión	0.318	0.185

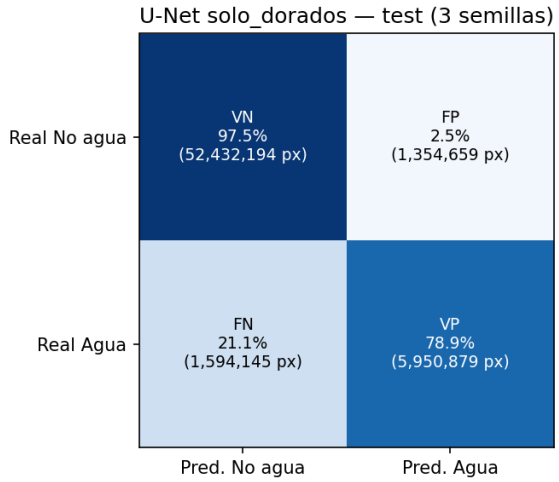


Figura 2. Matriz de confusión en test (suma de las 3 semillas).

zonas áridas. Las cifras lo confirman: el recall apenas cambia entre variantes (0.71–0.75), pero la comisión pasa de 0.178 con solo dorados a 0.249 con la mezcla y a 0.269 con solo débiles. Tercera: preentrenar con débiles y ajustar con dorados recupera el desempeño, pero queda empatado con usar solo dorados (la diferencia, 0.003, es menor que la desviación). Las etiquetas débiles no aportan información nueva: se derivan del mismo SAR que ya ve la red, con una regla que la red supera. El modelo final usa, por tanto, **solo los dorados con la pérdida combinada**.

V-C. Evaluación en distribución (test)

El modelo elegido en valid (pérdida combinada, solo dorados) se evaluó una única vez en test con sus tres semillas y umbral 0.5 (Tabla IV). Supera a Otsu en todas las métricas: el IoU sube de 0.554 a 0.669 (+0.114). La mejora viene sobre todo de la precisión (+0.133); el recall mejora menos (+0.041). Es decir, la red aprendió principalmente a *no* confundir con agua superficies oscuras que un umbral sí confunde.

Matriz de confusión (Fig. 2). El error dominante es la *omisión*: el 21.1 % del agua real se predice como no agua. En cambio, solo el 2.5 % del fondo se marca como agua. Esa tasa de comisión parece despreciable, pero como el fondo es mucho más abundante que el agua, equivale a 1.35 M de píxeles, suficientes para limitar la precisión a 0.815. Leída por filas, la matriz dice que el modelo es confiable cuando afirma

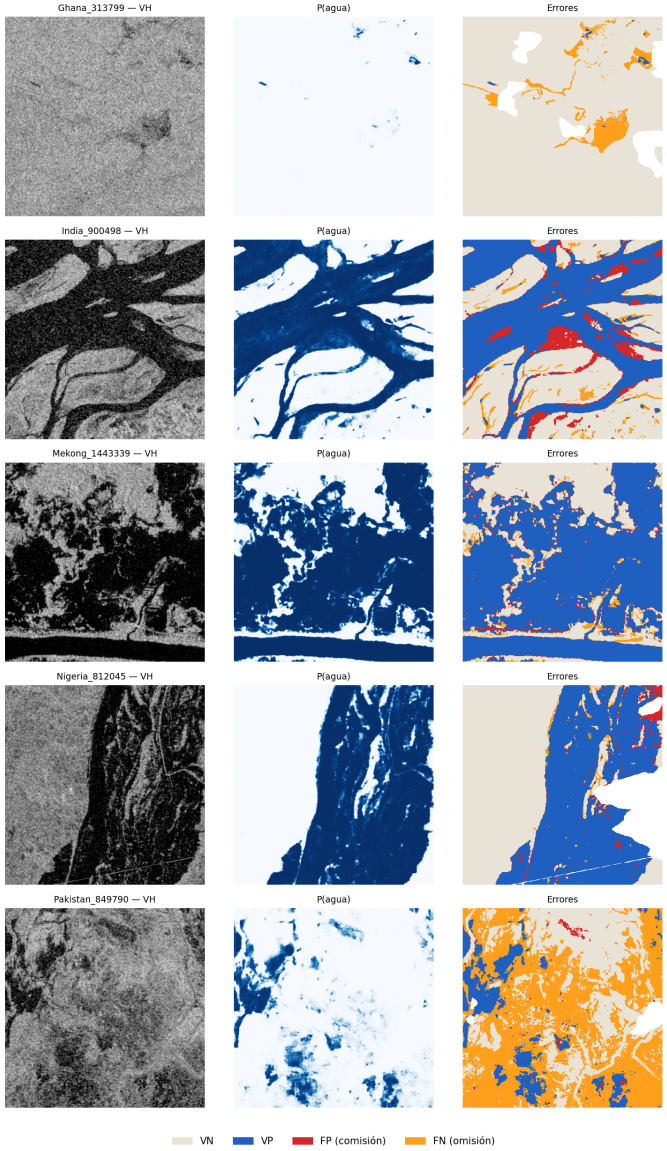


Figura 3. Mapas de error en test. Azul: VP; rojo: FP (comisión); naranja: FN (omisión); blanco: sin dato.

"no agua" y que, cuando falla, lo hace sobre todo por *no ver* agua que sí está.

Umbral. La curva IoU–umbral es casi plana entre 0.2 y 0.8. El umbral óptimo en valid (≈0.34) da 0.666 en test, sin diferencia apreciable con 0.5, así que mantenemos el umbral fijado de antemano: las probabilidades de la red están bien separadas.

Por evento. El promedio esconde mucha variación: Nigeria alcanza 0.887, mientras Pakistán cae a 0.194 con una omisión de 0.71. El agua perdida en Pakistán no es oscura en el SAR: es el caso de agua no especular que analizamos en la Sección V-E. La Fig. 3 muestra mapas de error representativos.

V-D. Generalización geográfica: Bolivia y Lima

Evaluamos el mismo modelo, sin ningún ajuste, en dos eventos que no vio (Tabla V, Fig. 4). Definimos la brecha

Tabla V
GENERALIZACIÓN A EVENTOS NO VISTOS (U-NET: 3 SEMILLAS).

Región	U-Net IoU	Otsu IoU	Brecha vs. test
Test (referencia)	0.669 ± 0.003	0.554	—
Bolivia	0.663 ± 0.026	0.718	0.8 %
Lima	0.003	0.011	99.5 %

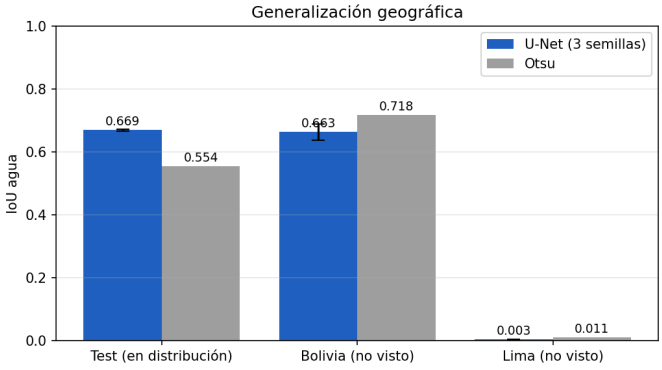


Figura 4. IoU por región: test, Bolivia y Lima, frente a Otsu.

como la caída relativa del IoU respecto a test, $(\mathrm{IoU}_{\text{test}} - \mathrm{IoU}_{\text{región}})/\mathrm{IoU}_{\text{test}}$.

Bolivia: generaliza. La brecha es menor que la variación entre semillas. La red es aquí más conservadora que Otsu (precisión 0.883, omisión 0.272), y Otsu la supera porque Bolivia es un caso favorable para un umbral: grandes extensiones de agua calma y oscura en una llanura de inundación.

Lima: colapsa. El IoU cae prácticamente a cero, y también el de Otsu: el problema no es la red, sino la señal. La Tabla VI lo muestra: en Lima, los píxeles que la etiqueta llama inundados tienen la *misma* retrodispersión que los no inundados (diferencia < 1 dB), mientras que en train el agua es 5–7 dB más oscura que el fondo. Ningún modelo que mire una sola imagen puede separar dos clases con la misma distribución.

Para entender por qué, descargamos dos escenas más de la misma órbita: antes (05/03) y después (29/03) del evento. En la zona inundada, la mediana de VV pasa de -9.63 a -8.75 y vuelve a -9.63 dB, y la de VH de -17.12 a -16.75 y luego a -17.37 dB, mientras una zona de control permanece estable. Es decir, el día del evento la zona inundada se *aclaró* en lugar de oscurecerse. Con esto planteamos las siguientes hipótesis:

- **H1 – La etiqueta no describe lo que vio el radar.** La capa EMSN038 es la máxima extensión potencial, delineada con imágenes ópticas de días posteriores. Parte del área etiquetada pudo no tener agua visible a las 10:38 UTC del 17/03, o tener solo lodo ya depositado.
- **H2 – Doble rebote y lodo saturado en zona urbana.** Entre edificaciones, el agua forma reflectores de esquina que *aumentan* la señal [8], y el barro húmedo y los escombros de un huaico son rugosos, no especulares. Es consistente con el aclaramiento medido.
- **H3 – Agua turbulenta en cauces angostos.** El flujo del huaico es rugoso, y los brazos inundados miden pocas decenas de metros: apenas unos píxeles de 10 m, dominados por el ruido *speckle*.

Tabla VI
MEDIANAS DE RETRODISPERSIÓN (DB) POR CLASE.

Conjunto	Clase	VV	VH
Train	agua	-14.92	-23.00
	no agua	-9.58	-16.03
Lima (17/03)	inundado	-10.79	-18.64
	no inundado	-10.14	-17.77

Tabla VII
TIPOS DE FALLO DEL SAR Y SU EVIDENCIA CUANTITATIVA.

Fallo (recorte)	Error	Evidencia
Sombra / incidencia rasante (Lima_0104)	FP	76.5 % de los FP con $\theta_{\text{local}} > 60°$ frente a 23.0 % del área (razón 3.3)
Doble rebote / lodo urbano (Lima_0506)	FN	ΔVV (17/03 − 05/03): $+1.22$ dB en zona inundada frente a $+0.03$ dB fuera
Agua no especular (Pakistan_849790)	FN	VH de los FN -18.1 dB, cerca del no agua (-16.3) y lejos del agua detectada (-24.9)
Agua no especular (Bolivia_314919)	FN	VH de los FN -22.0 dB, intermedio entre agua (-25.4) y no agua (-15.0)
Superficie seca y lisa (Pakistan_70625)	FP	VH de los FP -24.9 dB, tan oscuro como el agua real (-23.4)
Agua permanente (Lima_0506)	*FP*	*Descartada:* 0 % de los FP con ocurrencia JRC > 50 %

H2 se verifica de forma directa en la Sección V-E. Una cuarta hipótesis, que la etiqueta tratara el agua permanente de forma distinta a Sen1Floods11, se probó con JRC y se descartó (Sección V-E). Por todo esto reportamos Bolivia como el resultado cuantitativo de generalización y Lima como un caso negativo diagnosticado. Lima muestra un límite físico de la detección con intensidad de una sola fecha, más que un defecto del entrenamiento.

V-E. Análisis cualitativo de fallos

Buscamos los fallos del SAR que explican los errores de test y de Lima. Para no quedarnos en la inspección visual, cada tipo de fallo se acompaña de una prueba cuantitativa independiente, calculada con capas auxiliares descargadas sobre la grilla exacta del recorte (Tabla VII). Para las pruebas espaciales usamos la *razón de enriquecimiento*: el porcentaje de errores que cumple una condición dividido entre el porcentaje del área que la cumple. Si es mayor que 1, la condición concentra errores más de lo que su área explicaría.

1) Sombra de radar e incidencia rasante (FP). Con el relieve SRTM y la geometría de la pasada descendente calculamos el ángulo de incidencia local, $\cos\theta_{\text{local}} = \cos s \cos\theta + \sin s \sin\theta \cos(a - \phi)$, donde s es la pendiente, a la orientación de la ladera, θ el ángulo de incidencia y $\phi \approx 103°$ el azimut hacia el sensor. Las laderas que miran en sentido contrario al sensor reciben el pulso casi rasante y devuelven poca energía, igual que el agua. Los FP de la quebrada de Lima_0104 se

concentran ahí: su θ_{local} mediano es $66.9°$, frente a $47.2°$ en todo el recorte (Fig. 5).

2) Doble rebote y lodo en zona urbana (FN). En Lima_0506 la inundación del Rímac atraviesa zona urbana, y el modelo omite el 100 % de los píxeles inundados. La diferencia entre la imagen del evento y la de doce días antes muestra que esa franja se *aclaró* (Fig. 6): es la firma del doble rebote y del barro rugoso. Esta es la causa principal del colapso en Lima: el agua estaba, pero no se veía oscura.

3) Agua no especular (FN). En Pakistan_849790 se omite el 84 % del agua. El Sentinel-2 muestra agua de aspecto somero junto a vegetación (Fig. 7), pero su VH es casi igual al de la tierra: el viento, la vegetación emergente o la poca profundidad rompen la reflexión especular. Es el mecanismo detrás del peor evento de test (Pakistán, IoU 0.194). En Bolivia_314919 el efecto es más leve y se limita a los bordes y zonas de transición.

4) Superficie seca y lisa (FP). Es el error inverso. En Pakistan_70625 las parcelas en barbecho o recién preparadas son tan lisas como el agua para la longitud de onda de banda C, y su VH es incluso más oscuro que el del agua real (Fig. 8). Con una sola fecha de SAR estos FP son físicamente indistinguibles del agua. No descartamos que una parte sea riego no etiquetado, lo que haría el error ambiguo entre modelo y etiqueta. El mismo mecanismo explica la mancha oscura de Lima_0506, que ya era oscura antes del evento.

Hipótesis descartada. Probamos si los FP de Lima eran agua permanente que EMSN038 no etiqueta como inundación. Con la ocurrencia de agua de JRC (1984–2021), ningún FP cae donde hubo agua más de la mitad del tiempo, así que la descartamos. Reportarla es parte del análisis: el patrón no se explica por una diferencia de convención de la etiqueta.

V-F. Fusión con Sentinel-2 (bono)

Añadimos a la misma U-Net seis bandas de Sentinel-2 del mismo evento: B2, B3 y B4 (visible), B8 (NIR), y B11 y B12 (SWIR). Se concatenan a VV y VH como canales de entrada, lo que se conoce como fusión temprana. El agua absorbe casi toda la energía en NIR y SWIR, y con esas bandas la red tiene la información de los índices clásicos NDWI y MNDWI. Comparamos tres modos con el protocolo de siempre (3 semillas, pérdida combinada, selección en valid): solo SAR, solo óptico y fusión. Para que la comparación sea justa, los tres usan la *misma máscara*: se ignora todo píxel con SAR u óptico inválido, y por eso el modo SAR se volvió a entrenar. Su IoU en test (0.662) es consistente con el de la Sección V-C.

Cambio de IoU. La fusión sube el IoU de test en $+0.185 \pm 0.004$ respecto al SAR, con el mismo signo en las tres semillas, cuando se comparan corridas con la misma semilla (Tabla VIII, Fig. 9). La ganancia se mantiene en el evento no visto de Bolivia ($+0.127$).

¿De dónde viene la ganancia? Casi toda viene del óptico por sí solo, que ya alcanza 0.841 en test. Frente al óptico, la fusión gana apenas $+0.007$ en test y nada en Bolivia, diferencias dentro de la variación entre semillas. El SAR aporta otras cosas: *precisión* (la comisión en test baja de 0.090 a 0.063, y en Bolivia la precisión sube de 0.865 a 0.915) y *estabilidad* (la desviación en valid baja de 0.022 a 0.007). Nuestro modelo solo óptico es comparable con Prithvi [10], un modelo fundacional que, ajustado en Sen1Floods11 con estas mismas seis bandas, reporta un IoU de agua de 0.805 en test y 0.780 en Bolivia [11].

Tabla VIII
FUSIÓN CON SENTINEL-2: IOU (MEDIA ± DESVIACIÓN, 3 SEMILLAS) Y PRECISIÓN/RECALL EN TEST.

Entrada	Valid	Test	Bolivia	P_{test}	R_{test}
SAR (2)	$0.635 \pm .007$	$0.662 \pm .012$	$0.656 \pm .016$	0.810	0.784
Óptico (6)	$0.813 \pm .022$	$0.841 \pm .011$	$0.783 \pm .014$	0.910	0.917
Fusión (8)	$\mathbf{0.833 \pm .007}$	$\mathbf{0.848 \pm .009}$	$0.783 \pm .008$	0.937	0.899
Δ fusión $-$ SAR	$+0.198$	$+0.185$	$+0.127$		

Dónde ayuda. La fusión corrige precisamente los fallos de la Sección V-E (Fig. 10). En Pakistan_70625, los FP de las parcelas secas desaparecen y el IoU del recorte pasa de 0.58 a 0.81, porque en el óptico un campo seco no se parece al agua. En Pakistan_849790, el agua no especular empieza a detectarse (0.07 a 0.28), aunque sigue habiendo mucha omisión. En Bolivia_314919 se reducen las omisiones de los bordes.

Cautela. Este resultado no significa que el óptico sustituya al SAR. Las etiquetas de Sen1Floods11 se trazaron mirando ese mismo Sentinel-2, así que el óptico tiene una ventaja estructural frente a la etiqueta. Además, los etiquetadores excluyeron lo nublado: dentro de los píxeles etiquetados, menos del 0.3 % tiene aspecto de nube, de modo que el óptico solo se evalúa donde se ve. En una inundación real las nubes coinciden con el evento, y ahí el SAR es la única fuente. La fusión es un complemento valioso cuando hay una imagen óptica despejada y cercana en el tiempo, no un reemplazo.

VI. DISCUSIÓN CRÍTICA Y LIMITACIONES

La etiqueta define el techo. Las etiquetas de Sen1Floods11 se trazaron con ayuda del Sentinel-2 del mismo día. Parte del agua etiquetada es, por tanto, agua que el óptico ve y el SAR no (Pakistán, Sección V-E). Esto pone un techo al modelo solo SAR que ninguna arquitectura puede superar, y explica a la vez la gran ganancia de la fusión. Las cifras de E6 miden "qué tan bien se reproduce una etiqueta óptica", no solo "qué tan bien se detecta el agua".

Lima no es un fracaso del entrenamiento, pero tampoco una prueba limpia. La etiqueta EMSN038 es la máxima extensión delineada con imágenes ópticas de días posteriores, no el agua presente a la hora del paso del radar. Con un solo evento y 64 recortes con 1 % de agua, el IoU es además muy sensible. Lo que sí muestran los datos multitemporales es un límite físico: el agua urbana y de huaico se *aclara*, y un modelo de una sola fecha que aprendió "agua = oscuro" no puede detectarla. La salida no es más datos del mismo tipo, sino otra información: una imagen previa para detectar cambios [7] o la coherencia interferométrica [8].

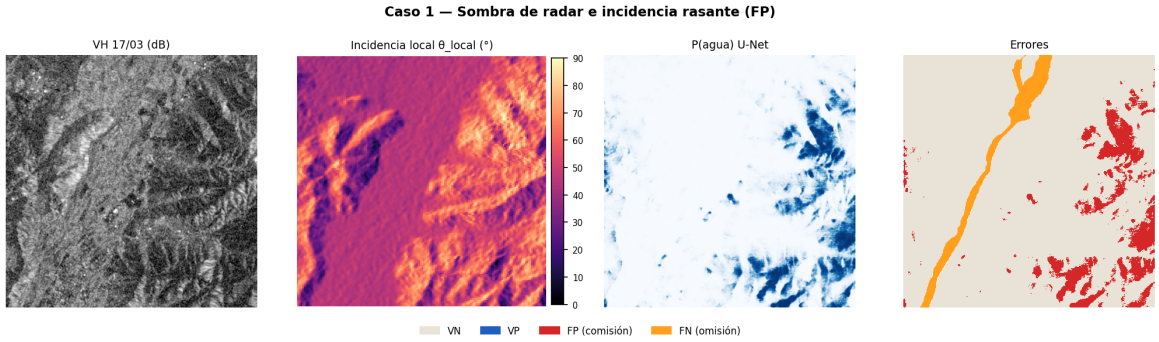


Figura 5. Caso 1 (Lima_0104): VH, incidencia local, probabilidad de agua y errores. Los FP (rojo) coinciden con las laderas de incidencia rasante.

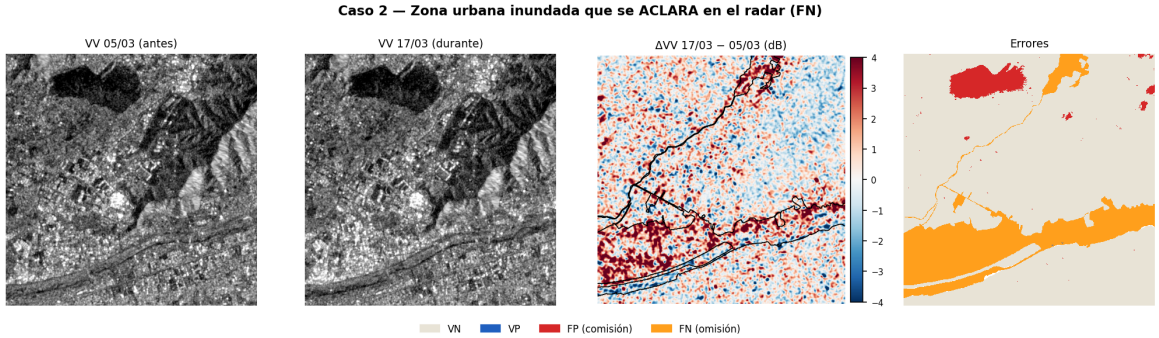


Figura 6. Caso 2 (Lima_0506): VV antes y durante, diferencia ΔVV con el contorno de EMSN038 y errores. La zona inundada se aclara (rojo en ΔVV) y se omite por completo.

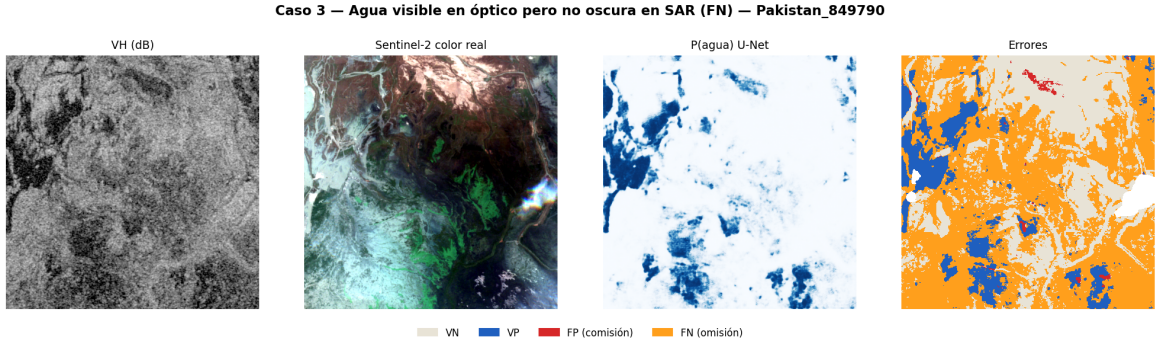


Figura 7. Caso 3 (Pakistan_849790): el agua visible en Sentinel-2 no es oscura en VH y se omite (naranja).

Tamaño de muestra y optimismo en distribución. Entrenamos con 252 recortes y estimamos la variabilidad con solo tres semillas. Test proviene de los mismos eventos que train, y la autocorrelación espacial entre recortes cercanos hace esa cifra optimista. La evaluación en Bolivia (15 recortes) es la más honesta, pero también la más ruidosa ($\pm$0.026). El IoU agregado, a su vez, está dominado por los recortes con mucha agua y oculta la variación entre eventos (de 0.19 a 0.89).

Decisiones no exploradas. Fijamos tasa de aprendizaje, profundidad, número de canales y umbral sin búsqueda de hiperparámetros, para no ajustar nada en función de test. No probamos ponderación de clases ni pérdida focal, aumentos radiométricos ni predicción con aumentos (TTA). Las rotaciones de 90° ignoran que la geometría de observación del SAR no es invariante a rotaciones (las sombras caen hacia el lado opuesto al sensor). En la ablación débil probamos una sola proporción de muestreo. Por último, las corridas en Kaggle usaron estadísticas de normalización redondeadas a tres decimales, una diferencia despreciable frente a la escala de los datos.

VII. Conclusiones

Una U-Net implementada desde cero con VV y VH supera al umbral de Otsu en Sen1Floods11 (IoU de test 0.669 frente a 0.554), sobre todo porque reduce las falsas alarmas. La pérdida combinada BCE + Dice y las conexiones de salto son

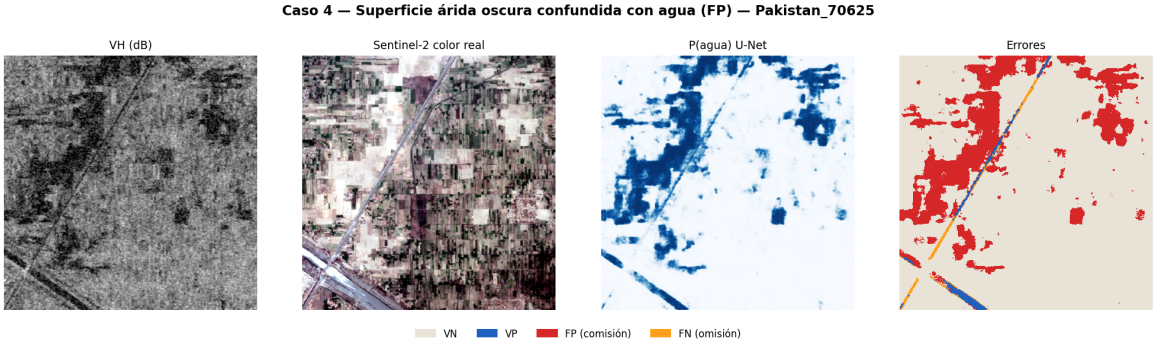


Figura 8. Caso 4 (Pakistan_70625): parcelas secas y lisas tan oscuras como el agua generan FP (rojo).

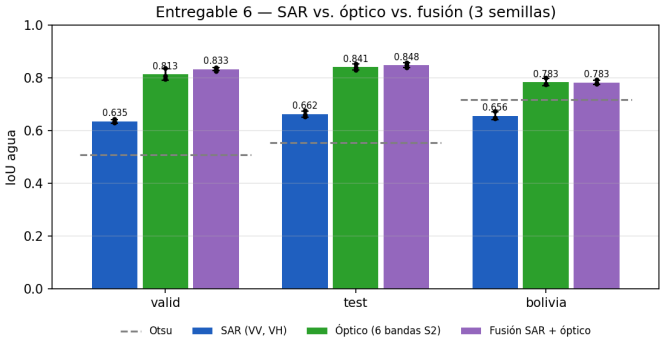


Figura 9. IoU por modo de entrada y partición; los puntos son las semillas y las líneas punteadas, Otsu.

las decisiones que más pesan. Las etiquetas débiles de Otsu no aportan, porque no contienen información que la red no extraiga del propio SAR.

El modelo generaliza a un evento no visto con agua calma (Bolivia, brecha de 0.8 %), pero colapsa en Lima 2017. Allí el agua urbana y de huaico se aclara en el radar, las laderas en incidencia rasante imitan al agua y la etiqueta óptica describe la extensión máxima. El análisis de fallos confirma cuatro mecanismos físicos con pruebas cuantitativas y descarta un quinto.

Añadir Sentinel-2 eleva el IoU de test a 0.848 (+0.185) y corrige justo esos fallos, pero la ganancia proviene casi por completo del óptico y está favorecida por cómo se etiquetaron los datos. Para un servicio operativo en el Perú, donde las inundaciones llegan con nubes, el siguiente paso es dar al modelo una dimensión temporal: una imagen SAR previa al evento para detectar cambios, y la coherencia interferométrica para el agua urbana. Lima es el caso de prueba natural para ambos.

Disponibilidad del código

El código (módulos `src/`, cuadernos por fase y resultados en CSV) está disponible en el repositorio público del proyecto en GitHub. https://github.com/AndherssonSalazar/mapeo-inundaciones-sar-unet.git

Referencias

[1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, ser. LNCS, vol. 9351, 2015, pp. 234–241.

[2] D. Bonafilia, B. Tellman, T. Anderson, and E. Issenberg, "Sen1Floods11: A georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2020, pp. 210–211.

[3] M. Bereczky, M. Wieland, C. Krullikowski, S. Martinis, and S. Plank, "Sentinel-1-based water and flood mapping: Benchmarking convolutional neural networks against an operational rule-based processing chain," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 15, pp. 2023–2036, 2022.

[4] H. Lee and W. Li, "Geospatial artificial intelligence for satellite-based flood extent mapping: Concepts, advances, and future perspectives," arXiv:2504.02214, 2025.

[5] F. Montello, E. Arnaudo, and C. Rossi, "MMFlood: A multimodal dataset for flood delineation from satellite imagery," *IEEE Access*, vol. 10, pp. 96 774–96 787, 2022.

[6] M. Wieland, F. Fichtner, S. Martinis, S. Groth, C. Krullikowski, S. Plank, and M. Motagh, "S1S2-Water: A global dataset for semantic segmentation of water bodies from Sentinel-1 and Sentinel-2 satellite images," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 1084–1099, 2024.

[7] N. I. Bountos, M. Sdraka, A. Zavras, I. Karasante, A. Karavias, T. Herekakis, A. Thanasou, D. Michail, and I. Papoutsis, "Kuro Siwo: 33 billion m^2 under the water. A global multi-temporal satellite dataset for rapid flood mapping," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, vol. 37, 2024.

[8] J. Zhao, Y. Li, P. Matgen, R. Pelich, R. Hostache, W. Wagner, and M. Chini, "Urban-aware U-Net for large-scale urban flood mapping using multitemporal Sentinel-1 intensity and interferometric coherence," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, p. 4209121, 2022.

[9] G. I. Drakonakis, G. Tsagkatakis, K. Fotiadou, and P. Tsakalides, "OmbriaNet—supervised flood mapping via convolutional neural networks using multitemporal Sentinel-1 and Sentinel-2 data fusion," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 15, pp. 2341–2356, 2022.

[10] J. Jakubik, S. Roy, C. E. Phillips, P. Fraccaro, D. Godwin *et al.*, "Foundation models for generalist geospatial artificial intelligence," arXiv:2310.18660, 2023.

[11] IBM and NASA, "Prithvi-EO-1.0-100M-sen1floods11: ficha del modelo ajustado en Sen1Floods11," Hugging Face, https://huggingface.co/ibm-nasa-geospatial/Prithvi-EO-1.0-100M-sen1floods11, 2023, consultado el 24 de octubre de 2026.

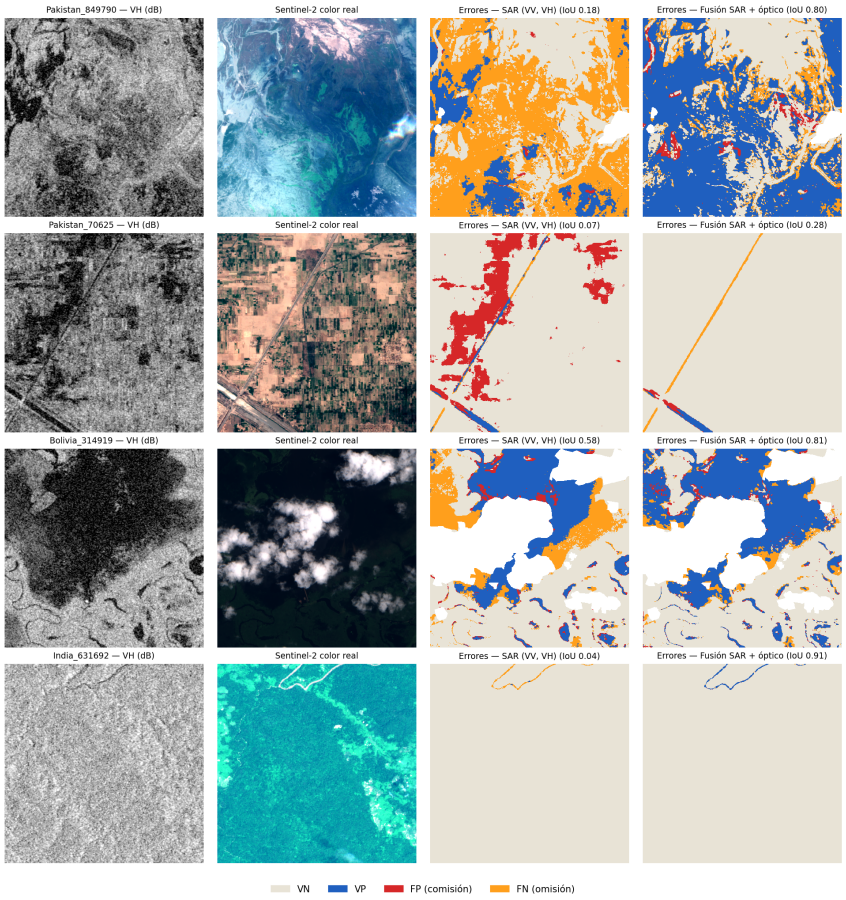


Figura 10. SAR frente a fusión en los casos de la Sección V-E: VH, Sentinel-2 en color real, errores con solo SAR y errores con la fusión (IoU del recorte en el título).